

Arabic Language Understanding Tools

Mustafa Jarrar
SinaLab, Birzeit University
Palestine

Artificial Intelligence

Opportunity
to invest in
Language
as **industry**
and
sustainable
R&D

The 4th Revolution

Opportunity
for
developing
countries to
compete and
impact



We build
tools and
resources
for NLU


Lexical Resources at SinaLab - Birzeit University

Lexicographic Database



150 lexicons
Largest Arabic lexicographic database

Arabic Ontology/ Wordnet



Formal Arabic Wordnet
with ontologically clean content

Annotated Corpora



Dialects,
NER, WSD, synonyms
Intents, hate
....

NLP library



APIs
Linguistic Data,
synonyms, Nested
NER, intents, ...

Synonyms 90s%

WSD 84%

NER 90s%

Intent 88.4%

Offensive 88.4%

Big Linguistic Data Graph

<https://ontology.birzeit.edu>



Natural Language Understanding Tools and Datasets



Open Source

<https://sina.birzeit.edu/resources>



SinaLab

News Team Resources

Resources

Download and try NLP/NLU datasets, corpora, tools and services

+ Lexicographic Database (150 lexicons)

حوسبة المعاجم

+ Arabic Ontology

الأنطولوجيا العربية

+ Dialect Corpora (Currasat)

كراسات مدونة العاميات

+ Arabic Synonyms

استخراج مترادفات

+ Named Entity Recognition (Wojood)

وجود - لاستخراج أسماء الاعلام

+ Word Sense Disambiguation (Salma)

سلمى - محلل دلالي

+ ArBanking77 Intent Detection

تحديد المقصود في المساعدات الآلية

+ Offensive Language Detection

خطاب الكراهية بالعبرية

+ Lemmatizer


+ NLP Tools



Copyright © 2023 Birzeit University

The Lexicographic Database

- The largest lexicographic Arabic database (150 Lexicons)
- Contains most lexicon types: glossaries, thesauri, bi/trilingual dictionaries, morph datasets, **Arabic Ontology**, and more.
- Covers most domains: science, technology, law, business, art, philosophy, ...
- Digitized over 10 years.



Some Statistics

150 Lexicons

Category	Lexical Concepts	Lexical entries	Synsets	Translations pairs	Glosses	Semantic relations
Total (Millions)	1.1 M	2.4 M	1.8 M	1.5 M	0.7 M	0.5 M
Sub Counts		1,100K Arabic 1,100K English 200K French 3K Others 1,300K Single-word 1,000K Multi-word	800K Arabic 800K English 200K French 50K Others	1,000K English-Arabic 300K English-French 200K French-Arabic	400K Arabic 300K English 1K Others	170K Sub-super links 29K Part-of links 260K Has-Domain links 30K Other links

- **API accessible** for NLP applications.

Natural Language Understanding Tools and Datasets



Open Source

<https://sina.birzeit.edu/resources>



SinaLab

News Team Resources

Resources

Download and try NLP/NLU datasets, corpora, tools and services

+ Lexicographic Database (150 lexicons)

حوسبة المعاجم

+ Arabic Ontology

الأنطولوجيا العربية

+ Dialect Corpora (Currasat)

كراسات مدونة العاميات

+ Arabic Synonyms

استخراج مترادفات

+ Named Entity Recognition (Wojood)

وجود - لاستخراج أسماء الاعلام

+ Word Sense Disambiguation (Salma)

سلمى - محلل دلالي

+ ArBanking77 Intent Detection

تحديد المقصود في المساعدات الآلية

+ Offensive Language Detection

خطاب الكراهية بالعبرية

+ Lemmatizer

+ NLP Tools



Copyright © 2023 Birzeit University



Arabic Ontology



- Characterization of the intended meaning (i.e., concepts) that the Arabic terms convey.
- Formal **Arabic Wordnet** - with ontologically-clean content.
- Linked with **PWN**, **Wikidata**, BFO, DOLCE
- Linked with many lexicons

The screenshot shows the Arabic Ontology website interface. At the top, there is a search bar and navigation tabs for 'Ontology', 'Dictionaries', and 'Morphology'. The 'Ontology' tab is selected. Below the search bar, there are checkboxes for 'Translations', 'Synonyms', and 'Definitions'. The main content area displays the concept 'Entity' (شيء) with its definition in Arabic and English. The definition in Arabic is 'أشياء موجودة أو ستوجد ونستطيع إدراكه أو تخيله' and in English is 'Whatever existed or will exist, and can be realized or imagined'. Below the definition, there is an example: 'كل شيء على ما يرام' (Everything as it is). The concept is identified by the ID '293198'. Below this, there are four sub-concepts listed with their definitions and examples:

- Object** (موجود | كائن | قائم | حقيقي | واقعي | شيء | ذات | قِيوم): An entity that is wholly and independently present in time, and is realized either for its concrete or social existence. Example: 'شيء له ذات مستقلة بنفسه، وحاضر كلياً في الزمن، ويُدرك بذاته قياساً أو لذاته اعتباراً'. ID: 293200. TypeOf: {Entity}.
- Occurrent** (سيرة | حدوث | حصول): An entity realized by the time of its happening. Example: 'الشيء الذي تُدرك ذاته وأجزائه بجريانه عبر الزمن'. ID: 293202. TypeOf: {Entity}.
- Dependent Entity** (منوط | مُعتمد | مُتعلّق | مشروط): An entity realized by the time of its happening. Example: 'شيء يعتمد وجوده على وجود أشياء أخرى'. ID: 293201. TypeOf: {Entity}.
- Abstract** (مجرد | تجريدي | غير مادي | نظري): An entity exists only in mind, cannot be measured or socially realized, and

The footer of the page includes the Birzeit University logo and the text 'Copyright © 2018'.

<https://ontology.birzeit.edu/concept/293198>



Arabic Ontology



- **Current size** so far (but the numbers are dynamic)
1800 fully-done concepts (mostly top levels)
17K partially investigated (ready for NLP applications)
Some branches are elaborated, other not yet.
- **English labels** are not our target - provided for readability and communication.
- **Methodology:** Built top-down and bottom-up at the same time.

▲ **occurent** | **مُبررة** | **حدث** | **حصول**
An entity realized by the time of its happening
الشيء الذي تُدرك ذاته وأجزائه بجريانه عبر الزمن
لا يمكن فهم أي حدث بشكل منفصل عن الإطار الزمني له
example: 293202  TypeOf : (entity)

▲ **process** | **عملية**
A cumulative occurent that is composed of a sequence of actions happening respectively in time
حدث تراكمي يتكون من سلسلة من الأفعال المترتبة، التي تحدث بشكل متتابع على خط الزمن
example: 293215  TypeOf : (occurent)

▲ **biological process** | **single-organism process** | **single organism process** | **physiological process**
عملية بيولوجية
A biological process represents a specific objective that the organism is genetically programmed to achieve. Biological processes are often described by their outcome or ending sta
See More..
45500019  TypeOf : (process) Ontologies  Collected

▲ **bodily process** | **عملية جسمانية**
A process in which at least one bodily component of an organism participates. | [OGMS_0000060]
455000574  TypeOf : (biological process) Ontologies  Collected


► **behavior** | **سلوك**
The internally coordinated responses (actions or inactions) of animals (individuals or groups) to internal or external stimuli, via a mechanism that involves nervous system activity. [GO_0007610]
455000020  TypeOf : (bodily process) Ontologies  Collected

► **mental process** | **عملية إدراكية**
A mental process is a bodily process that is of a type

<https://ontology.birzeit.edu/concept/293198>



Top Levels of the Arabic Ontology



Natural Language Understanding Tools and Datasets



Open Source

<https://sina.birzeit.edu/resources>



SinaLab

News Team Resources

Resources

Download and try NLP/NLU datasets, corpora, tools and services

+ Lexicographic Database (150 lexicons)

حوسبة المعاجم

+ Arabic Ontology

الأنطولوجيا العربية

+ Dialect Corpora (Currasat)

كراسات - مدونة اللهجات العربية

+ Arabic Synonyms

استخراج مترادفات

+ Named Entity Recognition (Wojood)

وجود - لاستخراج أسماء الاعلام

+ Word Sense Disambiguation (Salma)

سلمى - محلل دلالي

+ ArBanking77 Intent Detection

تحديد المقصود في المساعدات الآلية

+ Offensive Language Detection

خطاب الكراهية بالعبرية

+ Lemmatizer

+ NLP Tools



Copyright © 2023 Birzeit University

Seven morphologically-annotated Arabic dialect corpora (**1.35 million** tokens)

Curras2 كُراس : **Palestinian** dialect corpus (56K tokens)

Baladi بَلَدِي : **Lebanese** dialect corpus (10K tokens)

Nabra نَبْرَة : **Syrian** dialect corpus (60K tokens)

Lisan لِسَان : **Yemeni, Iraqi, Libyan, and Sudanese** dialects corpora

Yemeni (1.2 million), Iraqi (46K tokens), Libyan(52K tokens), Sudanese(53K tokens)



- El Haff, K., Jarrar, M., Hammouda, T., Zaraket, F., (2022). **Curras + Baladi: Towards a Levantine Corpus**. In Proceedings of the International Conference on Language Resources and Evaluation (LREC 2022), Marseille, France.
- Amal Nayouf, Tymaa Hammouda, Mustafa Jarrar, Fadi zaraket, Mohamad-Bassam Kurdy: **Nâbra: Syrian Arabic Dialects with Morphological Annotations**. In Proceedings of the 1st Arabic Natural Language Processing Conference (ArabicNLP), Part of the EMNLP 2023. ACL.
- Mustafa Jarrar, Fadi Zaraket, Tymaa Hammouda, Daanish Masood, Martin Waehlsch: **Lisan: Yemeni, Iraqi, Libyan, and Sudanese Arabic Dialect Corpora with Morphological Annotations**. The 20th ACS/IEEE International Conference on Computer Systems and Applications (AICCSA). Pages(-). IEEE. Egypt. 2023

313 results (4.6 secs)

Gloss	Lemma	POS	Suffix	Stem	Prefix	Word	Context
this way, this, thus	هيك / هكذا	ضمير اشارة		هيك	و/عطف	وهيك	... هيك ...
this way, this, thus	هيك / هكذا	ضمير اشارة		هيك	و/عطف	وهيك	... هيك ...
this way, this, thus	هيك / هكذا	ضمير اشارة		هيك	و/عطف	وهيك	... هيك ...
this way, this, thus	هيك / هكذا	ضمير اشارة		هيك	و/عطف	وهيك	... هيك ...
inon+like_that;thus	هيك	تعجب		هيك	ب/حرف جر	بهيك	... بهيك ...
inon+like_that;thus	هيك	تعجب		هيك	ب/حرف جر	بهيك	... بهيك ...
this way, like this, this, thus	هيك	ضمير اشارة		هيك		هيك	... هيك ...
inon+like_that;thus	هيك	تعجب		هيك	ب/حرف جر	بهيك	... بهيك ...

- ☒ Word
 ☒ Stem
 ☒ Lemma
 ☒ Gloss
 ☒ Whole Word
 ☐ Substring
- ☒ Palestinian
 ☒ Lebanese
 ☒ Iraqi
 ☒ Libyan
 ☒ Sudanese
 ☒ Yemeni

313 results (4.6 secs)

Gloss	Lemma	POS	Suffix	Stem	Prefix	Word	Context
be written/be fated/be destined write	كُتِبَ	فعل مضارع مفرد، مذكر، متكلم		كتب	و/عطف+/للمضارع المتكلم المفرد	واكتب	وراح اكون هدية واكتب وصية
be written/be fated/be destined write	كُتِبَ	فعل مضارع مفرد، مذكر، مخاطب		كتب	و/عطف+ب/إداة مضارعة+ت/للمضارع المخاطب المذكر المفرد	ويكتب	وتقد على القيس ويكتب
be written/be fated/be destined write	كُتِبَ	فعل ماضي مفرد، مذكر، مخاطب	ت/للماضي: فاعله مخاطب مذكر مفرد	كتب	و/عطف	وكتبت	وكتبت بوصيتك هو السبب
be written/be fated/be destined write	كُتِبَ	فعل مضارع مفرد، مذكر، غائب	ل/حرف جر+ها/ضمير متصل للغائب المؤنث المفرد	كتب	و/عطف+ي/للمضارع الغائب المذكر المفرد	ويكتبها	بس شوفت انو قبل كم يوم كان يحطها اغانتي ويحكي عنها ويكتبها . . . يا الله كيف
be written/be fated/be destined write	كُتِبَ	فعل مضارع مفرد، مذكر، غائب		كتب	ي/للمضارع الغائب المذكر المفرد	يكتب	الابن : (يكتب ستاتوس ع القيس) لا تتحدثوا عن الوجة اكثر الاشياء وجعا
be written/be fated/be destined write	كُتِبَ	فعل مضارع مجهول مفرد، مؤنث، غائب		نكتب	ت/للمضارع الغائب المذكر المفرد	تكتب	، وفرجيت كيف هاللقه تطورت من أنجق لهجه ما كان نيسوا تكتب للغه عالميه ما نيسوا ما تكتب .
be written/be fated/be destined write	كُتِبَ	فعل مضارع مجهول مفرد، مؤنث، غائب		نكتب	ت/للمضارع الغائب المذكر المفرد	تكتب	أنجق لهجه ما كان نيسوا تكتب للغه عالميه ما نيسوا ما تكتب .
scatter/sprinkle/write in prose	نُثِرَ	فعل مضارع مفرد، مذكر، غائب		نثر	ب/إداة مضارعة	ينثر	وينثر رماد
they (people) + write + (image of 1)	كُتِبَ	فعل مضارع	'و/للمضارع: فاعله مذكر جمع المذكر السالم'	كُتِبَ	ي/للمضارع الغائب المذكر المفرد	يُكْتُبُوا	و الكل يتكلم عن السفن الجرف الأجنبية و كل الصيادين بيغوا يكتبوا



Lemmas

Annotations

بصير



وظيفية



اسم



Count: 2

صَارَ صَارَ

ب+صير

فعل مضارع مفرد مذكر غائب
ب/أداة مضارعة
become/begin to

صَارَ صَارَ

ب+صير

فعل مضارع مفرد مذكر متكلم
ب/أداة مضارعة
become/begin to

Gloss	MSA Lemma	DA Lemma	Person	Gender	Number	POS	Suffix	Stem	Prefix	Token	Context	Dialect
how	كَيْفَ 1	شَلُون				أداة استفهام		شَلُون		شَلُون	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية
will/shall	سَوْفَ 1	رَخ رَاخ 3				أداة استقبال		دا		دا	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية
enter	تَخَلَّ 1	تَخَلَّ 1	مخاطب	مؤنث	مفرد	فعل مضارع	ي/للمضارع: فاعله مخاطب مؤنث مفرد	دخل	ت/للمضارع المخاطب المؤنث المفرد	تدخلي	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية
hand over/surrender	سَلَّمَ 1	سَلَّمَ 1	مخاطب	مؤنث	مفرد	فعل مضارع	ي/للمضارع: فاعله مخاطب مؤنث مفرد	سلم	ت/للمضارع المخاطب المؤنث المفرد	تسلمي	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية
in childbed	نَفْسَاء 1	نَفْسَاء 1		مؤنث	مفرد	اسم		نفسا	ع/حرف جر+ال/أداة تعريف	عالنفسا	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية
..	..	..				علامة ترقيم		..		..	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية
not	مَا 2	مَا 2				أداة نفي		ما		ما	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية
become/begin to	صَارَ	صَارَ	مذكر	مفرد	مفرد	فعل مضارع		صير	ب/أداة مضارعة	بصير	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية
to/for + Allah/God +	الله	الله	مذكر	مفرد	مفرد	اسم		الله	ي/أداة نداء	ياالله	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية
sisters sister/count	أَخْت 1	أَخْت 1	-	مؤنث	مفرد	اسم		خيتو		خيتو	شَلُون دا تدخلي تسلمي عالنفسا ... ما بصير يالله خيتو	حلبية

Natural Language Understanding Tools and Datasets



Open Source

<https://sina.birzeit.edu/resources>



SinaLab

News Team Resources

Resources

Download and try NLP/NLU datasets, corpora, tools and services

+ Lexicographic Database (150 lexicons)

حوسبة المعاجم

+ Arabic Ontology

الأنطولوجيا العربية

+ Dialect Corpora (Currasat)

كراسات مدونة العاميات

+ Arabic Synonyms

استخراج مترادفات

+ Named Entity Recognition (Wojood)

وجود - لاستخراج أسماء الاعلام

+ Word Sense Disambiguation (Salma)

سلمى - محلل دلالي

+ ArBanking77 Intent Detection

تحديد المقصود في المساعدات الآلية

+ Offensive Language Detection

خطاب الكراهية بالعبرية

+ Lemmatizer

+ NLP Tools



Copyright © 2023 Birzeit University

Extracting Synonyms from lexicographic graphs

A Benchmark and Scoring Algorithm for Enriching Arabic Synonyms

Sana Ghanem¹, Mustafa Jarrar¹, Radi Jarrar¹, Ibrahim Bounhas^{2,3}


¹Department of Computer Science, Birzeit University, Palestine

²LISI Laboratory of Computer Science for Industrial System, INSAT, Carthage University, Tunisia

³JARIR: Joint group for Artificial Reasoning and Information Retrieval, Tunisia

{swghanem, mjarrar, rjarrar}@birzeit.edu

ibrahim.bounhas@isd.uma.tn



A Benchmark and Scoring Algorithm for Enriching Arabic Synonyms

Dataset Construction

- Four Linguists (500 synsets, 3K synonyms in total).
- Each candidate synonyms was annotated with a **fuzzy value** by four different linguists.

مُخَالَفَة اِتِّحَاد فِدْرَالِي اِتِّحَاد فِدْرَالِي confederacy confederation federation				
a union of political organizations				
مُخَالَفَة ▼	60	نفس الدلالة، الأسلوب ضعيف ، غير شائعة		
اِتِّحَاد ▼	80	نفس الدلالة، الأسلوب صحيح ، شائعة الى حد قليل		
اِتِّحَاد ▼	100	نفس الدلالة والاسلوب والشيوع		
جَامِعَة ▼	60	نفس الدلالة، الأسلوب ضعيف ، غير شائعة		

Score	Meaning
100	Same semantics, style, use
90	Same semantics, style, less used
80	Same semantics, style, rarely used
70	Same semantics, style, not used
60	Close semantics, weak style, uncommon
50	Close semantics, not exact purpose
40	Semantically related
30	Semantically related (somehow)
20	Semantically different
10	Semantically very different
0	Semantically unrelated



[Home](#) > [Resources](#) > [Synonyms Generator](#)

Synonyms Generator

A dataset and source code for Synonyms Generator

Version: 1.0 (updated on 15/12/2022)

An algorithm to extend a set of synonyms with more synonyms. Given a set of synonyms, the algorithm builds a graph (using many dictionaries) and returns a set of candidate synonyms, each with a fuzzy value to indicate how much it is likely to be a synonym. The more synonyms in the input, the more accurate the candidate synonyms. We trained the fuzzy model using a dataset we built manually (500 synsets, with 3K candidate synonyms by four linguists). Please read this article for the details. Try the service (type synonym separated by | or , or -):

street | road | طريق | شارع

Extend

Evaluate

شارع 61% , طريق 62% , road 41% , street 41%

+ Settings

+ Dataset And Downloads

+ API

- Publications

Sana Ghanem, Mustafa Jarrar, Radi Jarrar, Ibrahim Bounhas: [A Benchmark and Scoring Algorithm for Enriching Arabic Synonyms](#). In Proceedings of the Global WordNet Conference (gwc2023), Donostia, January. 2023

[PDF](#) - [Slides](#) - [Video](#)

Demo



<https://sina.birzeit.edu/synonyms/>

Download: [Github.Synonyms](#)

A Benchmark and Scoring Algorithm for Enriching Arabic Synonyms

Extend a synset with more synonyms above a given fuzzy value

street | road | شارع | طريق Extend Accuracy: 0.14

route 31%, highway 31%, way 15%, via 15%, track 15%,
thoroughfare 15%, roadway 15%, road way 15%, ride
15%, path 15%, boulevard 15%, avenue 15%, Roadway
15%, Lane 15%, Boulevard 15%, Avenue 15%

سَبِيل 46%, سَبِيل 46%, مَمَر 31%, مَمَر 31%, مَسْلَك 31%, مَسْلَك 31%, صِرَاط 31%, صِرَاط 31%, مَو 31%, طَرِيق 31%, طَرِيق 31%, صِرَاط 31%, صِرَاط 31%, سَنَن 31%, سَنَن 31%, رُقَاق 31%, رُقَاق 31%, رُقَاق 31%, رُقَاق 31%, رُب 31%, رُب 31%, رُب 31%, رُب 31%, وَجَه 15%, وَجَه 15%, نَهَج 15%, نَهَج 15%

A Benchmark and Scoring Algorithm for Enriching Arabic Synonyms

Evaluate/rank synonyms in a given synset (wordnets, BERT's output, etc.)

street | road | شارع | طريق

Evaluate

61 شارع , %62 طريق% , road 41% , street 41%

Natural Language Understanding Tools and Datasets



Open Source

<https://sina.birzeit.edu/resources>



SinaLab

News Team Resources

Resources

Download and try NLP/NLU datasets, corpora, tools and services

+ Lexicographic Database (150 lexicons)

حوسبة المعاجم

+ Arabic Ontology

الأنطولوجيا العربية

+ Dialect Corpora (Currasat)

كراسات مدونة العاميات

+ Arabic Synonyms

استخراج مترادفات

+ Named Entity Recognition (Wojood)

وجود - لاستخراج أسماء الاعلام

+ Word Sense Disambiguation (Salma)

سلمى - محلل دلالي

+ ArBanking77 Intent Detection

تحديد المقصود في المساعدات الآلية

+ Offensive Language Detection

خطاب الكراهية بالعبرية

+ Lemmatizer

+ NLP Tools



Copyright © 2023 Birzeit University


Wojood

Nested Arabic Named Entity Corpus


Wojood

Nested Arabic Named Entity Corpus

Flat NER



Nested NER



Jarrar, M., Khalilia, M., Ghanem, S. (2022). Wojood: Nested Arabic Named Entity Corpus and Recognition using BERT. In Proceedings of the International Conference on Language Resources and Evaluation (LREC 2022), Marseille, France.

Wojood

❖ NER Corpus

Corpus	Nested?	size (tokens)	No. of entities	Entity classes	Which Arabic	Domain
Ontonotes5	No	300k	28k	18	MSA	News
ANERCorp	No	150k	11k	4	MSA	News
CanerCorpus	No	258k	72k	14	Classic	Religion
AQMAR	No	74k	-	open	MSA	4 domains
Wojood Corpus	YES	550K	75K	21	MSA & Dialect	Multi domains Media, History, Culture, Health, Finance, ICT, Law, Elections, Politics, Migration, Terrorism

❖ NER BERT

- Multi-task learning (nested entities)
- 88.4% F1-score

Annotation Guidelines

21 entity classes

PERS People names

فيروز، عادل إمام، ابن احمد، الملك عبدالله، النبي محمد

NORP Group of people

العرب، المسيحيين، سكان القدس، وزراء الخارجية العرب

OCC Occupation or professional title

رئيس جامعة بيرزيت، مدير بنك فلسطين، قائد الجيش

ORG Legal/social body

بنك القاهرة، ريال مدريد، داعش، الجيش المصري

GPE Geopolitical: country, city, state

ليبيا، مدينة القدس، الجمهورية اللبنانية، روسيا الاتحادية

LOC Geographical location (non-GPE)

البحر الميت، قناة السويس، آسيا، الوطن العربي

FAC Places: landmark, road, building..

مطار صنعاء، سجن ابو غريب، المسجد الأقصى

EVENT Events of general interest

حرب 1973، القمة العربية 2005، عيد الفطر ، يوم الأرض

DATE Specific/relative date (>day)

13 يونيو، 2019-2020، الفترة العثمانية

TIME Specific/relative time (<day)

الساعة ١٢ ، من الساعة 5 حتى 7 مساء، خلال ساعتين

LANGUAGE Human language or dialect

اللغة العربية، الفصحى، الدارجة المغربية، اللغة الفرنسية

WEBSITE Website or specific URL

موقع فيسبوك، يوتيوب schema.org ،

LAW Geographical location (non-GPE)

قانون الاستثمار ، المادة 114 من قانون العقوبات 2005

PRODUCT Vehicle, weapon, food, ...

مرسيدس سي ١٨٠، ايفون ١٣، دبابنة مركابا، تروفين

CARDINAL Numerals in digits/words

1.5 ، 30 ، 150 صفر، اثنان ، أربعة وعشرون ، مليون

ORDINAL does not refer to a quantity

٣ كيلومتر، مئة قدم ، 3 طن ، 50 غرام ، 25 سم مربع

PERCENT Word/symbol refers to a percent

5 بالمئة ، 10% ، 9 من كل الف

QUANTITY Value measured by units

٣ كيلومتر، مئة قدم ، 3 طن ، 50 غرام ، 25 سم مربع

UNIT Name/symbol of a unit

ميل ، كيلو ، كيلومتر ، إنش ، كيلوغرام ، هكتار ، مل

MONEY Monetary quantity, incl.

مئة وخمسون درهم اماراتي ، اثنان وثلاثون يورو ، 8 دولار

CURR Name/symbol of currency

دولار ، جنيه مصري ، دينار ، فرنك ، ريال سعودي € ،

Corpus Collection

Source - Topics	Sentences	Tokens
Web Articles ¹ (MSA) Health, Finance, ICT, Law, Elections, Politics, Migration and Terrorism	9,053	258,102
Archive ² (MSA) History and Culture	12,271	227,020
Social Media ³ (Dialect) General topics	5,653	65,342
Total	26,977	550,464

¹ un.org, hrw.org, msf.org, who.org, mipa.institute, elections.ps, sa.usembassy.gov, diplo- matie.ma, quora.com

² Awraq, Birzeit University Digital Palestinian Archive

³ Palestinian and Lebanese dialect corpora

Downloads and Demo

Birzeit University, in cooperation with the Edward Said Foundation, is organizing a folklore festival. The festival will start at 4:00 pm, on May 16, 2016, with the sponsorship of Bank of Palestine for an amount of five thousand dollars.

جامعة بيرزيت وبالتعاون مع مؤسسة ادوارد سعيد تنظم مهرجان للفن الشعبي، سيبدأ المهرجان الساعة الرابعة عصرا، بتاريخ 16/5/2016، وذلك برعاية من بنك فلسطين بمبلغ خمسة الاف ولار.

output format : highlighted ▼

جامعة بيرزيت GPE وبالتعاون مع مؤسسة ادوارد سعيد PERS ORG تنظم مهرجان للفن الشعبي، EVENT

سيبدأ المهرجان الساعة الرابعة عصرا، TIME بتاريخ 16/5/2022, DATE وذلك برعاية من بنك فلسطين GPE

بمبلغ خمسة الاف دولار CURRENCY MONEY ORG



<https://ontology.birzeit.edu/wojood>



ArabicNER



ArabicNER-Wojood

[illegible][illegible]

What Is Named Entity Recognition (NER) Used For?

Customer Support

Recognize and route per products, models, places, phones,

Content Recommendation

understand use profiles and history

Resumes

Recognize name, address, phone, etc.

Chatbots and Question Answering

Recognize names, amounts, places, etc.

Machine Translation

Transliterate entities....

Event Detection

Identify event as they occur (Finance/business events, social media,)

Knowledge Management

knowledge graphs, Digital libraries, content filtering

Classifying content for news providers

Efficient Search Algorithms

Finance

extract figures, loans, credit risk.

News providers

Natural Language Understanding Tools and Datasets



Open Source

<https://sina.birzeit.edu/resources>



SinaLab

News Team Resources

Resources

Download and try NLP/NLU datasets, corpora, tools and services

+ Lexicographic Database (150 lexicons)

حوسبة المعاجم

+ Arabic Ontology

الأنطولوجيا العربية

+ Dialect Corpora (Currasat)

كراسات مدونة العاميات

+ Arabic Synonyms

استخراج مترادفات

+ Named Entity Recognition (Wojood)

وجود - لاستخراج أسماء الاعلام

+ Word Sense Disambiguation (Salma)

سلمى - محلل دلالي

+ ArBanking77 Intent Detection

تحديد المقصود في المساعدات الآلية

+ Offensive Language Detection

خطاب الكراهية بالعبرية

+ Lemmatizer

+ NLP Tools



Copyright © 2023 Birzeit University

ArabGlossBERT: Fine-Tuning BERT on Context-Gloss Pairs for WSD

Moustafa Al-Hajj

Lebanese University

Beirut, Lebanon

moustafa.alhajj@ul.edu.lb

Mustafa Jarrar*

Birzeit University

Birzeit, Palestine

mjarrar@birzeit.edu

Context-Gloss Augmentation for Improving Arabic Target Sense Verification

Sanad Malaysha, Mustafa Jarrar, Mohammed Khalilia

Birzeit University, Palestine

{sanadmalaysha, mjarrar, mkhalilia}@birzeit.edu

SALMA: Arabic Sense-Annotated Corpus and WSD Benchmarks

Mustafa Jarrar, Sanad Malaysha, Tymaa Hammouda, Mohammed Khalilia

Birzeit University, Palestine

{mjarrar, smalaysha, thammouda, mkhalilia}@birzeit.edu

SALMA

ArabGlossBERT for Arabic Word-Sense Disambiguation

The Word Sense Disambiguation (WSD) Task

Given a word in a context, which sense (i.e. meaning) this word denotes?

You have beautiful eyes

Set of senses/meanings

1. the organ of sight
 2. good discernment (either visually or as if visually)
 3. attention to what is seen
 4. an area that is approximately central within some larger region)
 5. a small hole or loop
- 

SALMA

ArabGlossBERT for Arabic Word-Sense Disambiguation

The Word Sense Disambiguation (WSD) Task

Given a word in a context, which sense (i.e. meaning) this word denotes?

قصيدة من عيون الشعر

Set of senses

1. عُضُو الإِبْصَار فِي الْإِنْسَانِ وَالْحَيَوَانَ: لَهُ عَيْنَانِ كَعَيْنَيْ الصَّقْرِ - أَلَا إِنَّمَا الْعَيْنَانِ لِلْقَلْبِ رَائِدٌ ...
2. جَاسُوسٌ، "كَانَ عَيْنًا لِدَوْلَةٍ أجنبيةً . بَثَّ الْعَيُونُ : تَجَسَّسٌ، رَاقِبٌ - فَلَانٌ عَيْنٌ عَلَى فَلَانٍ : نَاطِرٌ عَلَيْهِ
3. أَجُودُ كُلِّ شَيْءٍ وَأَحْسَنُهُ وَنَفِيسُهُ: عَيُونُ الْفَنِّ.
4. حَارِسٌ: فَلَانٌ عَيْنٌ عَلَى الْمَكَانِ.
5. الْحَاضِرُ مِنْ كُلِّ شَيْءٍ أَصْبَحَ أَثَرًا بَعْدَ عَيْنٍ ...
6. عَيْنُ الْمَاءِ:- يَنْبُوعُهُ، تُحَلِّقُ الطَّيُورُ فَوْقَ عَيُونِ الْمَاءِ
7. عَيْنُ الشَّيْءِ:- نَفْسُهُ، ذَاتُهُ (تَسْتَعْمَلُ لِلتَّوَكِيدِ): جَاءَ الْقَوْمُ أَعْيُنَهُمْ - كُنَّا فِي الْمَكَانِ عَيْنَهُ.
8. عَيْنُ الْعَقْلِ:- قُدْرَةُ ذَهْنِيَّةٍ مَوْرُوثَةٍ عَلَى التَّخَيُّلِ وَتَذَكُّرِ الْأَحْدَاثِ.
9.

SALMA

ArabGlossBERT for Arabic Word-Sense Disambiguation

❖ Arabic context-gloss pairs Dataset (167k)

- Extracted from Birzeit University's Lexicographic database
- Annotated target words in context;

Gloss	Context	Label
[SEP] أجود كل شيء وأحسنه ونفيسه [SEP]	[CLS] قصيدة من عيون الشعر [SEP]	True
[SEP] ذاته (تستعمل للتوكيد) [SEP]	[CLS] قصيدة من عيون الشعر [SEP]	False
[SEP] ذاته (تستعمل للتوكيد) [SEP]	[CLS] جاء القوم أعينهم [SEP]	True
[SEP] أجود كل شيء وأحسنه ونفيسه [SEP]	[CLS] جاء القوم أعينهم [SEP]	False

❖ Three Fine-tuned BERT Models

- WSD into **binary sequence-pair classification task**
- **Accuracy 84%**
- 4 types of signals to emphasize target words in context

❖ Fine-tuned three Arabic pre-trained BERT models

The WSD task is converted into **binary sequence-pair classification task**

[CLS] قصيدة من عيون الشعر [SEP] أجود كل شيء وأحسنه ونفيسه [SEP] True
 [CLS] قصيدة من عيون الشعر [SEP] عين الشيء : نفسه ، ذاته (تستعمل للتوكيد) [SEP] False
 [CLS] جاء القوم أعينهم [SEP] عين الشيء : نفسه ، ذاته (تستعمل للتوكيد) [SEP] True
 [CLS] جاء القوم أعينهم [SEP] أجود كل شيء وأحسنه ونفيسه [SEP] False

النتائج (F1) : 84 (AraBERTv02) ، 82 (CAMELBERT) ، 80 (QARIB)

❖ Results

Model	True False		Accuracy
AraBERTv02	Precision	81 85	84
	Recall	66 93	
	F1-score	72 89	
CAMELBERT	Precision	77 83	82
	Recall	60 92	
	F1-score	67 87	
QARIB	Precision	73 82	80
	Recall	58 90	
	F1-score	65 86	

Constructing a dataset of context-gloss pairs

Statistics:

	count
Unique Lemmas (undiacritized)	26169
Avg glosses per Lemmas	1.25
Unique Glosses	32839
Unique Contexts	60272
Avg context per gloss	1.83
True context-gloss pairs	60323
False context-gloss pairs	106884
Total True and False pairs	167207

Training and Test Datasets


- every context selected in the test set should not be selected in the training set;
- every gloss should be selected in both the training and the test sets.

Datasets	Pairs	Count	Total
Training	True pairs	55,585	152,035
	False pairs	96,450	
Test	True pairs	4,738	15,172
	False pairs	10,434	
		Total	167,207

Download: <https://ontology.birzeit.edu/downloads>

SALMA

End-to-end WSD system (using TSV)





Try



SALMA سلمى

A corpus and model for Arabic Word Sense Disambiguation (WSD).

Version: 1.0 (updated on 22/10/2023)

قصيدة من عيون الشعر

WSD

« قصيدة (قَصِيدَة 1 303044571): مجموعة من الأبيات الشعرية متحدة في الوزن والقافية والرؤي وهي تتكوّن من سبعة أبيات فأكثر "قصيدة غزليّة".

يَبْتُ القصيدة : البيت المتضمّن غاية الشّاعر، أو أنفس أبياتها، أو مثل يُضرب في تفضيل بعض الشّيء على كلّ - مطلع القصيدة : أوّل بيت منها

« من (من 1)

« عيون (عَيْن 2 303038477): أجود كلّ شيء وأحسنه ونفيسه "قصيدة من عيون الشعر - عيونُ الفنّ".

« الشعر (شِعْر 1 303029103): كلام موزون مقفّى قصداً يعتمد على التخيل والتأثير؛ ليوحي بإحساسات مؤثّرة وصور خياليّة "شعر صافي الديباجة

- نظم الشّعْر - ما الشّعْر إلّا شعورُ المرء يُرسله ... عفو البديهة عن صدق وإيمانٍ - إِنَّ مِنَ الشّعْرِ لَحِكْمَةٌ [حديث] - حَوْماً عَلَمَنَاهُ الشّعْرَ وَمَا يَنْبَغِي لَهُ< يس/

69 ". أنشدّه الشّعْر : قرأه عليه - أوأبدُ الشّعْر : ما لا تُماثلُ جودته أو قوافيه الشاردة - ربّة الشّعْر : إلهة الشّعْر عند الوثنيين - شطرا بيت الشّعْر : الصدر

+ Description

+ Downloads

ArabGlossBERT

Arabic Word-Sense Disambiguation



Arabic Language Understanding Tools

Confirm

صورة لعيون جميله

Tokenize

Lemmatize

NER

WSD

« صورة (صُورَة 1 303032440): (الطبيعة والفيزياء) ما تراه العين مباشرة أو من خلال عدسة أو في مرآة أو مرتدّ عنها على سطح ما

« لعيون (عَيْن 2 303038475): (التشريح) عُضْو الإبصار في الإنسان والحيوان "له عينان كعَيْنَي الصقر - ألا إنما العينان للقلب رائدٌ ... فما تألفَ العينان فالقلب آلفُ - <فَرَجَعْنَاكَ إِلَى أُمِّكَ كَيْ تَقَرَّ عَيْنُهَا> طه/ 40 - <وَلِتُصْنَعَ عَلَى عَيْنِي> طه/ 39 : لتصنع تحت رعايتي وحفظي وإكرامي". أَخَذَ بَعَيْنَ الاعتبار : قَدَّرَ، راعى أمراً ما - أصابته العَيْنُ : حُسِدَ - أغمض عَيْنَه عنه : تجاهله، تغافل - أنت على عَيْنِي : يقال في الإكرام والحفظ جميعاً - إنسان العَيْنُ :

ArabGlossBERT

Arabic Word-Sense Disambiguation



Arabic Language Understanding Tools

اعمل بجامعة بيرزيت وأحب زيت الزيتون



 BIRZEIT UNIVERSITY

جميع الحقوق محفوظة © 2022 جامعة بيرزيت

<https://sina.birzeit.edu/salma/>

Natural Language Understanding Tools and Datasets



Open Source

<https://sina.birzeit.edu/resources>



SinaLab

News Team Resources

Resources

Download and try NLP/NLU datasets, corpora, tools and services

+ Lexicographic Database (150 lexicons)

حوسبة المعاجم

+ Arabic Ontology

الأنطولوجيا العربية

+ Dialect Corpora (Currasat)

كراسات مدونة العاميات

+ Arabic Synonyms

استخراج مترادفات

+ Named Entity Recognition (Wojood)

وجود - لاستخراج أسماء الاعلام

+ Word Sense Disambiguation (Salma)

سلمى - محلل دلالي

+ ArBanking77 Intent Detection

تحديد المقصود في المساعدات الآلية

+ Offensive Language Detection

خطاب الكراهية بالعبرية

+ Lemmatizer

+ NLP Tools



Copyright © 2023 Birzeit University

ArBanking77: Intent Detection Neural Model and a New Dataset in Modern and Dialectical Arabic

Mustafa Jarrar
Birzeit University
Birzeit, Palestine
mjarrar@birzeit.edu


Ahmet Birim
Sestek
Istanbul, Türkiye
ahmet.birim@sestek.com

Mohammed Khalilia
Birzeit University
Birzeit, Palestine
mkhalilia@birzeit.edu

Mustafa Erden
Sestek
Istanbul, Türkiye
mustafa.erden@sestek.com

Sana Ghanem
Birzeit University
Birzeit, Palestine
swghanem@birzeit.edu

Chatbots need to detect intents before answering
➔ build an Arabic intent dataset, and train BERT.



- | C | D | E | F | G | H | I |
|-----|--|--|--------|--|---------------|--------------|
| Qid | Question_en | Question_MSA1 | n_MSA2 | Question_PAL1 | Question_PAL2 | Intent_en |
| 1 | 1 I am still waiting on my card? | ما زلت أنتظر بطاقتي؟ | | بعندي يستنى في البطاقة؟ | | card arrival |
| 1 | 2 What can I do if my card still hasn't arrived after 2 w | ماذا أفعل إذا لم تصل بطاقتي بعد أسبوعين؟ | | ايش بزم أعمل اذا بطاقتي ما وصلت بعد أسبوعين | | card arrival |
| 1 | 3 I have been waiting over a week. Is the card still coi | انا أنتظر منذ أكثر من أسبوع. هل ما زالت البطاقة قادمة؟ | | هه صارلي أكثر من أسبوعين يستنى، لساتها البطاقة؟ | | card arrival |
| 1 | 4 Can I track my card while it is in the process of deliv | أبلكاني تتبع بطه هل ممكني تتبع بطاقتي أثناء عملية التسليم؟ | | بقدر أنتبع بطاقتي وهي بعملية التسليم؟ | | card arrival |
| 1 | 5 How do I know if I will get my card, or if it is lost? | كيف أعرف إذا ما كنت سأحصل على بطاقتي ، أو إذا ضاعت | | كيف بقدر أعرف اذا راح أخذ بطاقتي ولا ضاعت؟ | | card arrival |
| 1 | 6 When did you send me my new card? | متى بعثت لي بطاقتي الجديدة؟ | | متى بعثتلي بطاقتي الجديدة؟ | | card arrival |
| 1 | 7 Do you have info about the card on delivery? | هل هناك معلومات عن البطاقة عند التسليم؟ | | عندكم معلومات عن بطاقة النفع عند الاستلام؟ | | card arrival |
| 1 | 8 What do I do if I still have not received my new card | ما الذي علي فعله اذا لم استلم بطاقتي الجديدة؟ | | ايش بقدر أعمل اذا ما اخذت بطاقتي الجديدة؟ | | card arrival |
| 1 | 9 Does the package with my card have tracking? | هل هناك تتبع للحال يتم تتبع الحزمة مع بطاقتي؟ | | بقدر أتبع الحزمة يلي بتجي مع بطاقتي؟ | | card arrival |
| 1 | 10 I ordered my card but it still isn't here | طلبت بطاقتي لكنك طلبت بطاقتي لكنها ما زالت غير موجودة | | بطاقتي الي وصيت عليها لساتها طلبت بطاقتي بس لساتها مش موجودة. | | card arrival |
| 1 | 11 Why has my new card still not come? | لماذا بطاقتي الجد لماذا لم تصل بطاقتي الجديدة؟ | | ليش بطاقتي لساتها ما اجت؟ | | card arrival |
| 1 | 12 I still haven't received my card after two weeks, is it | لأن لم استلم بطه ما زلت لم استلم بطاقتي بعد أسبوعين ، هل فقت؟ | | صارلي اسبوعين ما استلمت بطه ، اسبوعين ما استلمت بطاقتي، معقول ضاعت؟ | | card arrival |
| 1 | 13 Can you track my card for me? | أبلكانك تتبع بطه هل ممكنك تتبع بطاقتي من أجلي؟ | | ممكن تتبيلي بطاقتي؟ | | card arrival |
| 1 | 14 Is there a way to track the delivery of my card? | هل هناك طريقة لتتبع تسليم بطاقتي؟ | | هل طريقة أتتبع تسليم بطاقتي؟ | | card arrival |
| 1 | 15 It's been a week since I ordered my card and it's nom | مر أسبوع على ما فقت مر أسبوع منذ ان طلبت بطاقتي وهي ليست هنا. ارجو | | فيكم تساعدوني بخصوص البطاقة صارلي أسبوع يستنى بالبطاقة، ممكن تساعدوني؟ | | card arrival |
| 1 | 16 Will I be able to track the card that was sent to me? | أيمكنني تتبع البطا من سأتسلم من تتبع البطاقة التي تم إرسالها إلي؟ | | في إمكانية أتتبع البطاقة الي بعنو بقدر أتتبع البطاقة التي انبعثتلي؟ | | card arrival |
| 1 | 17 I don't have my card in 1 week. Should I be worried | منذ أسبوع ولم ألد املك بطاقتي خلال أسبوع واحد. يجب ان أكون قلقا؟ | | في اشي داعي للقلق عشان بطاقتي أسبوع بطاقتي مش معي، لازم أقلق؟ | | card arrival |

❖ Intent detection model

- F1-scores: MSA (%92) and PAL (%90)



ArBanking77

A dataset and source-code for ArBanking77

Version: 1.0 (updated on 1/9/2023)

ArBanking77 consists of 31,404 (MSA and Palestinian dialect) that are manually Arabized and localized from the original English Banking77 dataset; which consists of 13,083 queries. Each query is classified into one of the 77 classes (intents) including card arrival, card linking, exchange rate, and automatic top-up. A neural model based on AraBERT was fine-tuned on the ArBanking77 dataset (F1-score 92% for MSA, 90% for PAL). Try the service (type sentences separated by newLine or ؟ or ? or ! or .):

يا ريت يتم توقيف البطاقة

Detect

- Downloads

ArBanking77 is available to download upon request for academic and commercial use.

[Request to download ArBanking77](#) (whole dataset 31,404 queries, MSA 15,537 queries, Palestinian Dialect 15,867 queries)

[GitHub](#) (download BERT training source code + sample data (~1K queries))

[Hugging Face](#) (download fine-tuned BERT model, ready to use)

+ API

- Publications

Mustafa Jarrar, Ahmet Birim, Mohammed Khalilia, Mustafa Erden, Sana Ghanem: [ArBanking77: Intent Detection Neural Model](#)



Download



Offensive Language Detection in Hebrew

Offensive content {Hate | Violence | Racist | Abusive} in Hebrew is growing.

Type of Offence:

Class	Sub-Class	Definition
Offensive	Abusive	If the tweet contains direct or implicit insults using vulgar or street words.
	Hate	If the tweet contains criticism, attack, or degrade, directly or implicitly, because of race, color, religion, nationality, or gender.
	Pornographic	If the tweet promotes or invites any pornographic or sexual arousal.
	Violence	If the tweet endorses an act that involves physical harm towards any party, regardless of the reason.

Offensive Language Detection in Hebrew


- Collect 16K tweets,
- classify each tweet with different tags,
- then, train a deep learning model – to automatically detect offensive content.

Tweet	English Translation	Annotations
גירוש, הריסת בתים, מאסרי עולם ללא אפשרות חנינה, אחרת יהיה עוד יותר גרוע. להתייחס אליהם כמו אל מחבלים.	Deportation, demolition of houses, life sentences without the possibility of amnesty, otherwise it will be even worse. Treat them like terrorists.	Class: Violence, Hate Target: Palestinians Topic: punish Palestinians Phrase: Deportation, Demolition of houses, life sentences, terrorists
אין כבר הרתעה. לא מפחדים מהמשטרה. אני חושב שהגיע הזמן על פי מראות ההפגנות וההתפרעויות בימים האחרונים, כמו שאמר פעם רבין בתחילת האינתיפאדה: „לשבור להם את העצמות". זה יש כבר אינתיפאדה של התפרעויות.	There is no more deterrence. We are not afraid of the police. I think the time has come to face the demonstrations and riots, as Rabin once said at the beginning of the intifada: "to break their bones." There is already an intifada of riots here.	Class: Violence, Hate Target: Palestinians Topic: Demonstrations Phrase: Break their bones
ימח שמה וזכרה @Onetruth011 של אילנה דיין. העיתונאית הכי מנוולת ושקרנית שאני מכיר. ממש מרשעת.	May the name and memory of Ilana Dayan be remembered. The most depraved and lying journalist I know. Really sinister.	Class: Abusive Target: Ilana Dayan Topic: Journalism Phrase: Sinister, Depraved, Lying
פרצופו האמיתי של @judash0 אבי ביטון נחשף לעיני כל. מדובר בשמאלני, אנטי ציוני, עוכר ישראל, בוגד שממומן ע"י הקרן החדשה להפיל את שלטון הימין ולהעלות את המפלגות הערביות לשלטון כדי להוביל למדינת כל אזרחיה	Avi Beaton's true face clear now. This is a leftist, anti-Zionist, oppressor of Israel, a traitor who is financed to overthrow the right-wing government and bring the Arab parties to power in order to lead to a state for all its citizens.	Class: Hate, Abusive Target: Avi Bitton, Arab Parties Topic: politics Phrase: Traitor, Anti-Zionist
ה. וא לא @rabea_bader רלוונטי אם אתה דרוזי, סורי, אנטי ציוני ומגעיל שכמוך.	@rabea_bader is irrelevant if you are Druze, Syrian, anti-Zionist and disgusting like you.	Class: Hate, Abusive Target: Rabea Bader, Druze, Syrian Topic: Racism Phrase: disgusting, anti-Zionist
אתה לפחות @Ahmad_tibi לא משקר - היית ונשאתר לאומן ערבי שרוצה בחורבן ישראל כמדינה יהודית.	@Ahmad_tibi At least you're not lying - you were and remain an Arab nationalist who wants the destruction of Israel as a Jewish state.	Class: Hate Target: Ahmad Tibi Topic: Political views Phrase:

Offensive Language Detection in Hebrew


Data set	# of training examples		Validation data	Test data	Accuracy	
	Our data	D_{OLaH}			He BERT	Aleph BERT
D_1	1,750	0	250 (ours)	500 (ours)	63%	68%
D_2	1,750	1,013	250 (ours)	500 (ours)	58%	63%
D_3	1,750	2,026	250 (ours)	500 (ours)	61%	63%
D_4	0	1,418	203 (D_{OLaH})	405 (D_{OLaH})	79%	86%
D_5	1,250	1,418	203 (D_{OLaH})	405 (D_{OLaH})	81%	79%
D_6	2,500	1,418	203 (D_{OLaH})	405 (D_{OLaH})	81%	82%
D_7	0	2,026	203 (D_{OLaH})	500 (ours)	60%	57%
D_8	2,500	0	250 (ours)	405 (D_{OLaH})	64%	69%

Offensive Language Detection in Hebrew



Offensive Language Detection in Hebrew

Download Corpus and models




The screenshot shows the GitHub repository page for SinaLab / OffensiveHebrew. The repository is public and has 1 branch and 0 tags. The main branch is selected. The repository contains a file named tag_vocab.pkl, which was added 2 hours ago. The README.md file is visible, and the repository is licensed under CC-BY-NC-SA 4.0.

Hebrew Corpus

This corpus contains offensive language in Hebrew manually annotated. The data includes 15,881 tweets, labeled with one or more of five classes (abusive, hate, violence, pornographic, or non-offensive). The corpus is annotated manually by Arabic-Hebrew bilingual speakers.

The Corpus



The screenshot shows the Hugging Face model card for SinaLab / OffensiveHebrew. The model card is licensed under CC-BY-NC-SA 4.0 and has 0 likes. The model card is titled "Hebrew Corpus" and describes the corpus as containing offensive language in Hebrew manually annotated. The data includes 15,881 tweets, labeled with one or more of five classes (abusive, hate, violence, pornographic, or non-offensive). The corpus is annotated manually by Arabic-Hebrew bilingual speakers.

Model Download

Huggingface:
<https://huggingface.co/SinaLab/OffensiveHebrew>

Downloads last month: 0

Natural Language Understanding Tools and Datasets



Open Source

<https://sina.birzeit.edu/resources>



SinaLab

News Team Resources

Resources

Download and try NLP/NLU datasets, corpora, tools and services

+ Lexicographic Database (150 lexicons)

حوسبة المعاجم

+ Arabic Ontology

الأنطولوجيا العربية

+ Dialect Corpora (Currasat)

كراسات مدونة العاميات

+ Arabic Synonyms

استخراج مترادفات

+ Named Entity Recognition (Wojood)

وجود - لاستخراج أسماء الاعلام

+ Word Sense Disambiguation (Salma)

سلمى - محلل دلالي

+ ArBanking77 Intent Detection

تحديد المقصود في المساعدات الآلية

+ Offensive Language Detection

خطاب الكراهية بالعبرية

+ Lemmatizer

+ NLP Tools



Copyright © 2023 Birzeit University

References

1. Mustafa Jarrar, Sanad Malaysha, Tymaa Hammouda, Mohammad Khalilia: SALMA: Arabic Sense-Annotated Corpus and WSD Benchmarks. In Proceedings of the 1st Arabic Natural Language Processing Conference (ArabicNLP), Part of the EMNLP 2023. ACL.
2. Amal Nayouf, Tymaa Hammouda, Mustafa Jarrar, Fadi zaraket, Mohamad-Bassam Kurdy: Nâbra: Syrian Arabic Dialects with Morphological Annotations. In Proceedings of the 1st Arabic Natural Language Processing Conference (ArabicNLP), Part of the EMNLP 2023. ACL.
3. Mustafa Jarrar, Ahmet Birim, Mohammed Khalilia, Mustafa Erden, and Sana Ghanem: ArBanking77: Intent Detection Neural Model and a New Dataset in Modern and Dialectical Arabic. In Proceedings of the 1st Arabic Natural Language Processing Conference (ArabicNLP), Part of the EMNLP 2023. ACL.
4. Haneen Lqreina, Mustafa Jarrar, Mohammed Khalilia, Ahmed Oumar El-Shangiti, Muhammad AbdulMaged: Arabic Fine-Grained Entity Eecognition. In Proceedings of the 1st Arabic Natural Language Processing Conference (ArabicNLP), Part of the EMNLP 2023. ACL.
5. Mustafa Jarrar, Muhammad Abdul-Mageed, Mohammed Khalilia, Bashar Talafha, AbdelRahim El-madany, Nagham Hamad, Alaa' Omar: WojooodNER 2023: The First Arabic Named Entity Recognition Shared Task. In Proceedings of the 1st Arabic Natural Language Processing Conference (Arabic- NLP), Part of the EMNLP 2023. ACL.
6. Nouran Khallaf, Elin Arfon, Mo El-Haj, Jon Morris, Dawn Knight, Paul Rayson, Tymaa Hammouda, Mustafa Jarrar: Open-source thesaurus development for under-resourced languages: a Welsh case study. The 4th LDK Conference on Language, Data and Knowledge, Vienna, Austria, 12-15 September 2023
7. Nagham Hamad, Mustafa Jarrar, Mohammad Khalilia, Nadim Nashif: Offensive Hebrew Corpus and Detection using BERT. The 20th ACS/IEEE International Conference on Computer Systems and Applications (AICCSA). IEEE. Egypt. 2023
8. Sana Ghanem, Mustafa Jarrar, Radi Jarrar, Ibrahim Bounhas: A Benchmark and Scoring Algorithm for Enriching Arabic Synonyms. The 12th International Global Wordnet Conference (GWC2023), Global Wordnet Association. (pp.). San Sebastian, Spain, 2023
9. Sanad Malaysha, Mustafa Jarrar, Mohammad Khalilia: Context-Gloss Augmentation for Improving Arabic Target Sense Verification. The 12th International Global Wordnet Conference (GWC2023), Global Wordnet Association. (pp.). San Sebastian, Spain, 2023
10. Mustafa Jarrar, Mohammed Khalilia, Sana Ghanem: Wojoood: Nested Arabic Named Entity Corpus and Recognition using BERT. In Proceedings of the International Conference on Language Resources and Evaluation (LREC 2022), Marseille, France. 2022
11. Mustafa Jarrar, Fadi Zaraket, Tymaa Hammouda, Daanish Masood, Martin Waehlich: Lisan: Yemeni, Iraqi, Libyan, and Sudanese Arabic Dialect Corpora with Morphological Annotations. The 20th ACS/IEEE International Conference on Computer Systems and Applications (AICCSA). Pages(-). IEEE. Egypt. 2023 arXiv, DOI 10.48550/ARXIV.2212.06468. 2023
12. Karim El Haff, Mustafa Jarrar, Tymaa Hammouda, Fadi Zaraket: Curras + Baladi: Towards a Levantine Corpus. In Proceedings of the International Conference on Language Resources and Evaluation (LREC 2022), Marseille, France. 2022
13. Mustafa Jarrar: The Arabic Ontology - An Arabic Wordnet with Ontologically Clean Content. Applied Ontology Journal, 16:1, 1-26. IOS Press. 2021
14. Moustafa Al-Hajj, Mustafa Jarrar: ArabGlossBERT: Fine-Tuning BERT on Context-Gloss Pairs for WSD. In Proceedings of the International Conference on Recent Advances in Natural Language Processing (RANLP 2021). PP 40--48, 2021
15. Moustafa Al-Hajj, Mustafa Jarrar: LU-BZU at SemEval-2021 Task 2: Word2Vec and Lemma2Vec performance in Arabic Word-in-Context disambiguation. In Proceedings of the Fifteenth Workshop on Semantic Evaluation (SemEval2021) Task 2: Multilingual and Cross-lingual Word-in-Context Disambiguation (MCL-WIC). PP 748--755, Association for Computational Linguistics. 2021
16. Eman Naser-Karajah, Nabil Arman, Mustafa Jarrar: Current Trends and Approaches in Synonyms Extraction: Potential Adaptation to Arabic. In Proceedings of the 2021 International Conference on Information Technology (ICIT). PP 748--755, Association for Computational Linguistics. pp. 428-434, IEEE. 2021
17. Mustafa Jarrar, Eman Karajah, Muhammad Khalifa, Khaled Shaalan: Extracting Synonyms from Bilingual Dictionaries. The 11th International Global Wordnet Conference (GWC2021), Global Wordnet Association. (pp. 215-222). Pretoria, South Africa, 2021
18. Kareem Darwish, Nizar Habash, Mourad Abbas, Hend Al-Khalifa, Huseein T. Al-Natsheh, Houada Bouamor, Karim Bouzoubaa, Violetta Cavalli-Sforza, Samhaa R. El-Beltagy, Wassim El-Hajj, Mustafa Jarrar, Hamdy Mubarak: A Panoramic Survey of Natural Language Processing in the Arab World. Communications of the ACM, April 2021, Vol. 64 No. 4, Pages 72-81
19. Mustafa Jarrar: Digitization of Arabic Lexicons. Arabic Language Status Report. UAE Ministry of Culture and Youth. Pages 214-2017. Dec 2020
20. Mustafa Jarrar, Hamzeh Amayreh: An Arabic-Multilingual Database with a Lexicographic Search Engine. The 24th International Conference on Applications of Natural Language to Information Systems (NLDB 2019). Pages(234-246). LNCS 11608, Springer. 2019
21. Mustafa Jarrar, Hamzeh Amayreh, John P. McCrae: Representing Arabic Lexicons in Lemon - a Preliminary Study. The 2nd Conference on Language, Data and Knowledge (LDK 2019). Pages(29-33). CEUR, Volume 2402. ISSN:1613-0073. Leipzig, Germany. 2019
22. Diana Alhafi, Anton Deik, Mustafa Jarrar: Usability Evaluation of Lexicographic e-Services. The 16th IEEE/ACS International Conference on Computer Systems and Applications (AICCSA). Pages(1-7). IEEE. Abu Dhabi, UAE. 2019
23. Mustafa Jarrar, Fadi Zaraket, Rami Asia, Hamzeh Amayreh: Diacritic-Based Matching of Arabic Words. ACM Asian and Low-Resource Language Information Processing. Volume 18, No 2, Pages(10:1-10:21), ACM, ISSN:2375-4699. December, 2018
24. Mustafa Jarrar: Search Engine for Arabic Lexicons. The 5th Conference on Translation and the Problematics of Cross-cultural Understanding. The Forum for Arab and International Relations. Doha, Qatar. December, 2018
25. Diab Abuaiadah, Dileep Rajendran, Mustafa Jarrar: Clustering Arabic Tweets for Sentiment Analysis. The 2017 IEEE/ACS 14th International Conference on Computer Systems and Applications. Pages(499-506). IEEE Computer Society. ISBN:9781538635810. (doi.10.1109/AICCSA.2017.162). Hammamet, Tunisia. 2017
26. Mustafa Jarrar, Nizar Habash, Faec Alrimawi, Divam Akra, Nasser Zalmout: Curras: An Annotated Corpus for the Palestinian Arabic Dialect. Journal Language Resources and Evaluation. Pages(745-775). Volume(51)